#42 【超入門】AIの情報漏洩を対策！絶対知っておきたいセキュリティ基礎を教えるで

https://www.youtube.com/watch?v=2Rdppb837vc ／ 42:21

3行要約

- AIのせいで攻撃する側が強くなり、これまで狙われなかった個人や小さなサイトまで標的になりうる時代のセキュリティ入門。
- 最低限やるべきは「学習設定をオフ」「カード番号・パスワードは入れない」「利用規約を確認」。
- AIエージェント用にパソコンを分ける、権限を渡しすぎない、素人がWebアプリを公開しない、が3本柱。

主なポイント

- 背景：AIエージェントは自分で反応を見ながら攻撃を続けられるうえ、安全装置を外したAIも出回っている。大量に一斉攻撃でき、一般人も「その他大勢」として巻き込まれうる。
- ① 🔑 **学習（「モデル改善のためにデータを使う」）はオフにする。クレジットカード番号・パスワードはAIに入れない。チャットの「共有URL」で公開しない。** 簡単にできる対策を怠る理由はない（→#16）。
- 利用規約を読む。学習をオフにできない（全データを取ると書いてある）サービスもある。また大企業でもデータ漏えい事故は起きる。
- ② AIエージェントを使うときは「漏れる前提」で考える。🔑 **一番簡単で確実なのは、AI用のパソコンを分けること**（古いPCを初期化して使うのも可）。経営者の中には、AI用に別のWi-Fiまで用意する人もいる。
- 細かい対策を重ねるより、隔離した方が便利さと安全を両立しやすい。仮想環境（VMware、サンドボックス）も手段だが「これで万全」ではない。
- **権限を渡しすぎない。** 全部許可するモード（Claude Codeの危険な権限スキップ、Codexのフルアクセス）は避け、自動モードなど安全寄りの設定で使う。OpenClawや素性の分からない海外製AIは特に注意。
- AIへの攻撃手口の例：Webページに隠し命令を仕込み、AIにAPIキーなどを言わせようとする（大手AIは対策が進んでいる）。ソフトの公式アップデート自体が乗っ取られる事例も増えている。

- ③ 🔑 **Webサービス・アプリとして自分のPCやAIをネットに公開するのは、セキュリティの難易度が一気に上がる。** 住所を公開して鍵をかけ忘れたような状態になりかねない。公開するならAIに「セキュリティの観点を洗い出して」「攻撃テスト（ペネトレーションテスト）をして」と頼み、それでも慎重に。
- そもそも個人アプリは儲かりにくい。スプレッドシートやパソコン内で動く簡単なアプリで済むことも多い。
- 結論：セキュリティかAIかの二択ではなく両方必要。状況は数か月で変わるので、リスクと得られるものを比べて判断し続ける。

紹介されたテクニック

- **学習設定をオフにする**：各AIの設定にある「モデル改善のためにデータを使う」のような項目をオフにする。チェックを1つ外すだけでできる最低限の対策で、オンのままだと自分のデータを学習に使ってよいと認めたことになる。
- **カード番号・パスワードは入力しない**：クレジットカード番号やパスワードはAIのチャットに貼らない。どんな会社でも漏えい事故は起こりうるので、「入れない」が一番確実。
- **チャットの共有URLに注意**：ChatGPTなどの「共有（URLで公開）」機能を使うと、そのURLを知っている人は誰でも中身を見られる。秘密の情報が入った会話は共有しない。
- **利用規約を確認する**：使う前に規約で「データを学習に使うか」「オフにできるか」を確認する。中には全データを取ると書かれていて設定で止められないサービスもあるので、そういうものは重要な用途に使わない。
- **AI用のパソコンを分ける**：AIエージェント（パソコンを自分で操作するAI）を使うときは「漏れる前提」で考え、使っていない古いPCを初期化してAI専用にするなど、大事なデータが入ったPCと分ける。細かい対策を積み重ねるより、隔離したほうが便利さと安全を両立しやすい。会社の場合は、社内とは別のWi-Fiを用意する人もいる。
- **仮想環境で切り分ける**：もう少し勉強するなら、VMwareやサンドボックス（パソコンの中に隔離された作業場所を作る仕組み）でAIの作業場所を分ける。ただし「これで万全」ではない点に注意。
- **権限を渡しすぎない**：Claude Codeの「危険な権限スキップ」やCodexの「全部許可（フルアクセス）」のようなモードは使わず、自動モードなど安全寄りの設定で使う。OpenClawや素性の分からない海外製AIは別PCで使うか、そもそも使わない。

- **怪しい要求に気づく**：AIがWebページを読んだあと急に「APIキー（サービスの合鍵となる文字列）を教えて」などと言い出したら、ページに隠し命令が仕込まれている可能性を疑う。
- **素人のWeb公開は避け、公開前にAIで点検**：自分のPCやアプリをネットに公開すると難易度が一気に上がる。どうしても公開するなら、AIに「セキュリティの観点を洗い出して」「攻撃テスト（ペネトレーションテスト）をして」と頼み、個人情報は持たない設計にする。
- **アプリにせず簡単な形で済ませる**：本当にWebアプリが必要か考える。レシート集計ならスプレッドシートで十分なことも多く、配るならパソコン内で動く簡単なアプリ（exeファイル）にすればネットに公開せずに済む。
- **アップデートにも注意を払う**：最近は公式のソフト更新そのものが乗っ取られる事例もあるので、エージェントやプログラムを使う人は、追加部品（パッケージ）の更新に関するセキュリティ情報も調べておく。

紹介されたツール ChatGPT、Claude Code、Codex、OpenClaw（要注意）、Claude Mythos（攻撃能力が高く話題）、VMware・サンドボックス、Vercel・Supabase（アプリ公開用）

すぐ実践できること

- 使っているAIすべてで「学習に使う」設定がオフになっているか今日確認する。
- AIにパスワードやカード番号を貼らないことを徹底する。
- AIエージェントを本格的に使うなら、使っていない古いPCをAI専用にすることを検討する。